



Stage 15 end-to-end QPS with one HNSW graph per shard

× Baseline-B ◆ Random broadcast ■ K-Means routing



Stage 15 中文图解

用途：在每个逻辑 shard 只有一张非空 HNSW 图、worker 与客户端物理核隔离的条件下，重测 1~4 台真实机器的端到端吞吐。

如何理解：横轴 M 同时是真实主机数和逻辑 shard 数；点为重复均值，误差条为 95% 置信区间，M=1 旁的叉号是全部测点后的 baseline-B。

最终结论：M=4 时 SIFT Random/K-Means 为 6,965/13,775 QPS；GloVe 为 3,616/3,397 QPS。单图控制没有使端到端 QPS 自动按机器数增长。

证据边界：这是满足 $\text{Recall}@10 \geq 0.90$ 的服务级结果；它包含 fan-out、scatter/gather、合并、负载偏斜和固定 ef 成本，不能只用单张 HNSW 图的局部复杂度解释。