





Local HNSW work reduction versus aggregate fan-out work

Random broadcast K-Means routing



Stage 15 中文图解

用途：直接验证分图后单个被访问 shard 的图搜索工作是否下降，以及该下降是否被访问更多 shard 的总工作抵消。

如何理解：下排把每查询距离计算除以实际 P，接近局部单图工作；上排是服务真正承担的每查询总工作。局部下降但总量上升时，QPS 不应上升。

最终结论：SIFT Random 从 M=1 到 M=4 的每 shard 距离工作变为 0.90×，但每查询总距离工作变为 3.61×；局部收益被 P=4 的广播放大项抵消。

证据边界：距离计算是硬件计数器推导的工作代理；它不含网络等待和结果合并，但比仅用 wall-clock QPS 更能定位局部图与总服务成本的差异。